# LEADER-DimASQP

## 面向维度ASQP的语言特定编码器与数据感知集成细化系统

*Language-Specific Encoder and Data-Aware Ensemble Refinement for Dimensional ASQP*

**汇报人：秦洪振[1,2] · 铃木美美[2] · 福本文代[2] · 周仁杰[1]**

[1] 杭州电子科技大学计算机学院, 中国 杭州 310018
[2] 日本山梨大学大学院, 日本 甲府 400-8511

# 维度 Aspect 情绪四元组预测 (Dimensional ASQP) 任务特性

## 什么是维度 ASQP (DimASQP)？

- **任务定义**：从句子中抽取 Aspect 项、Opinion 项、Entity-Attribute 类别，并预测其**连续的 Valence-Arousal (V-A) 情绪值**。
- **四元组形式**：`Y = {(a_i, c_i, o_i, V_i, A_i)}`，其中 Valence（效价）与 Arousal（唤醒度）属于 `[1, 9]` 的实数区间。
- **严苛的度量指标**：官方采用 **cF1 (Continuous F1)**，仅在 categorical 部分 `(a, c, o)` **完全匹配**时才授予 true positive 分数，再乘以基于 V-A 欧氏距离的折扣因子。**一步错，全盘皆输**。

## 当前面临的三大系统挑战

- **结构抽取的耦合性**：如何保证 Aspect 和 Opinion 边界抽取的**高精确度**？抽取的微小偏差就会让该四元组得分为零。
- **低资源多语言极度不平衡**：英语、中文、日文、俄文、鞑靼文 (Tatar)、乌克兰文，各语言规模从 1,240 到 6,050 不等，低资源语言**极易过拟合**。
- **连续回归的中心化倾向**：模型倾向于将 V-A 分数回归到中性区间 `[5.0, 5.0]` 以规避损失，导致**缺乏边界特征的区分度**。

文献来源: Lee et al. DimABSA: Building multilingual and multidomain datasets... arXiv:2601.23022 (2026)

核心思路与策略 / OUR CORE PHILOSOPHY

# LEADER-DimASQP: 多语言场景下因地制宜的设计理念

## 学术核心发问：是否存在单一通用大模型？

- **统一多语言配方的局限性**：不同语言由于其分词特性、形态学结构和领域分布存在本质差异，单一通用模型无法实现多源最优。
- **分词机制的影响**：如日文存在复杂的助词修饰，中文包含紧凑的字词边界。**分词器的匹配偏置**常常决定了特征抽取的上限。

## LEADER 系统的解决路线：架构底座 + 精细选型

- **架构稳定底座**：首创结合 **Rethink反馈反馈机制** 与 **匈牙利集合匹配** 训练，稳定边界预测与连续坐标回归。
- **多语因地制宜**：针对每个数据集，**自主调配与验证最优编码器与后处理策略**，而非生搬硬套统一预训练模型。

**核心系统成果 (System Highlights)**

**在八大开发集上，LEADER-DimASQP 取得 0.5008 平均 cF1，相比强大的 Llama-3.3 70B 跃升了 +11.46 pp，并在日文酒店、鞑靼语餐饮、中文餐饮上刷新了目前已公开学术界最高水平！**

系统底座架构 / BASE SYSTEM ARCHITECTURE

# 轻量级重思考反馈机制 (Rethink Feedback) 与匈牙利集合匹配

## 1. 轻量重思考反馈 (Rethink)

将第一阶段输出的 BIO 边界、分类概率、V-A 连续预测进行特征嵌入，并**无损反馈 (fused) 回原始 Token 隐藏状态**。

在不调用二次编码器的前提下，让第二阶段预测头获得“软先验信息”，**大幅稳定复杂的边界细化**。

## 2. 匈牙利集合匹配 (Hungarian)

候选 Aspect-Opinion 匹配极易因笛卡尔积组合爆炸而崩溃。

我们将分类损失、边界重合度、V-A 连续 Huber 距离融合，构建一个代价矩阵。**通过 Hungarian 算法解最优指派**，将传统排序预测转化为**稳定的集合匹配学习**。

## 3. 训练三神器 (Stabilizers)

- **对抗防御 (FGM)**：对隐藏表征施加轻微扰动（`epsilon=0.1`），缓解过拟合。
- **滑动均值 (EMA)**：在权重更新中应用 `0.999` 衰减，平滑噪音。
- **检查点优选**：保留 dev cF1 前 3 佳的最佳模型进行无偏评估。

相关文献: Kuhn (1955) The Hungarian method; Carion et al. (DETR, ECCV 2020); Miyato et al. (Adversarial, ICLR 2017)

数据层自定义 / DATA-AWARE AUGMENTATION & TRANSFER

# 基于回译验证、COMET 过滤与源语跨域迁移策略

## 高质量文本增强：回译验证与 COMET 过滤

- **多枢轴回译 (BT)**：利用德、法、中、俄等多路径语言做中间枢轴。最关键的是**子串验证机制**——只有当原始标签中的 Aspect/Opinion 子串在回译句子中被完整定位时才保留标签，拒绝漂移数据。

- **大模型润色与 COMET 质量控制**：使用 DeepSeek 润色句子，并采用 **`COMET-Kiwi`** 进行质量评估。发现 **COMET 过滤门槛存在“甜点区” (0.96)**，门槛过低引入噪声，过高（如 0.965）则导致训练量骤减出现欠拟合。

## 跨语言热启动迁移 (Cross-lingual Transfer)

- **寻找最佳中转源**：分析 8 大数据集，中文餐饮 (**`zho_restaurant`**) 包含最多的训练句子 (**6,050 条**)，是语义与关联知识最充沛的微调源头。

- **跨语言源模型引导**：使用在中文餐饮上微调的最优检查点，作为非结构化低资源语言 (Russian, Tatar, Ukrainian) 的**热启动参数**。结果证实，这种源迁移对不均衡小样本的提升极为巨大。

文献来源: Sennrich et al. (Improving NMT with Monolingual Data, ACL 2016); Rei et al. (CometKiwi, WMT 2022)

因地制宜配置 / PER-DATASET CONFIGURATION

# 语言特定的编码器与定制化推理配置

## 日文酒店 (jpn_hotel)

Language-Specific Encoder

**推荐模型：`ku-nlp/deberta-v2-large-japanese`**

针对日文形态学特点引入。结合 **MeCab 分词器辅助进行后处理**，裁剪掉预测 Span 末尾多余的助词和助动词，实现边界精准对齐。

## 中文电脑 (zho_laptop)

Domain & Pretraining Match

**推荐模型：`hfl/chinese-roberta-wwm-ext-large`**

中文特定 Large 预训练，捕获细腻的硬件专有名词。使用 **top-k=0.10** 解码控制，大幅缓解由于电脑领域词汇多样性带来的 False Negatives。

## 俄文餐饮 (rus_restaurant)

Encoder Scaling

**推荐模型：`xlm-roberta-large`**

出人意料的是，俄文专用 ruRoberta 效果不如多语言 **`XLM-R-large`**。说明多语言模型的**跨语迁移泛化能力**在少样本回归上优势更甚。

## 乌克兰餐饮 (ukr_restaurant)

Base Model + BT + Paraphrase

**推荐模型：`mdeberta-v3-base`**

小语种在 Base 模型下表现同样顽强。在 **mDeBERTa-base** 基础上融入混合回译数据与 DeepSeek 润色，实现了泛化性能的最大化突破。

开发集效果评测 / EXPERIMENTAL RESULTS

# 在八大开发集上与官方多语言基线的对比

| 测试系统 (System) | Eng-R | Eng-L | Jpn-H | Rus-R | Tat-R | Ukr-R | Zho-R | Zho-L | 均值(Mean) |
|---|---|---|---|---|---|---|---|---|---|
| **Llama-3.3 70B (SOTALLM)** | 0.5048 | 0.2483 | 0.3577 | 0.4118 | 0.3702 | 0.4070 | 0.4391 | 0.3506 | **0.3862** |
| **GPT-OSS 120B** | 0.5013 | 0.2411 | 0.4151 | 0.3683 | 0.3094 | 0.3663 | 0.4249 | 0.3551 | 0.3727 |
| **GPT-5 mini 0-shot** | 0.4036 | 0.2304 | 0.0907 | 0.2508 | 0.1974 | 0.2465 | 0.2481 | 0.1356 | 0.2254 |
| **Kimi K2 0-shot** | 0.3740 | 0.2805 | 0.1309 | 0.2656 | 0.2310 | 0.2974 | 0.2975 | 0.1569 | 0.2542 |
| **Shared-Task Average** | 0.5398 | 0.2908 | 0.3259 | 0.4526 | 0.3581 | 0.4446 | 0.4728 | 0.3602 | 0.4056 |
| **LEADER-DimASQP (Ours)** | **0.6949** | **0.3304** | **0.4500** | **0.5267** | **0.4821** | **0.5068** | **0.5669** | **0.4487** | **0.5008** |

### 核心成绩解析 (Key Results Analysis)

- **碾压式优势**：平均 cF1 到达 **0.5008**，相较 Llama-3.3 70B 提高 **+11.46 pp**，相较官方评测平均线提高 **+9.52 pp**！
- **刷榜地标**：在**日文酒店 (0.4500)**、**鞑靼餐饮 (0.4821)**、**中文餐饮 (0.5669)**上，全面超越了目前公开汇报的所有参赛队最好成绩。

消融分析 / ABLATION STUDIES

# 五种子集成 (5-Seed Ensemble) 对边界与情绪稳定的奇效

| 数据集 (Dataset) | 最佳单模型 | 单模平均 | 5-Seed集成 | 集成净收益 (Gain) |
|---|---|---|---|---|
| **jpn_hotel (日文酒店)** | 0.4128 | 0.4026 | 0.4466 | +4.40 |
| **rus_restaurant (俄文餐饮)** | 0.4817 | 0.4699 | 0.5267 | +5.68 |
| **zho_laptop (中文电脑)** | 0.4010 | 0.3940 | 0.4487 | +5.47 |
| **ukr_restaurant (乌克兰餐饮)** | 0.4736 | 0.4541 | 0.5068 | +5.27 |
| **tat_restaurant (鞑靼餐饮)** | 0.4282 | 0.4047 | 0.4821 | +7.74 |
| **zho_restaurant (中文餐饮)** | 0.5234 | 0.5083 | 0.5669 | +5.86 |
| **八大任务均值 (Mean)** | 0.4614 | 0.4495 | 0.4970 | +4.76 |

### 集成为什么如此有效？

- 在 DimASQP 任务中，**精确边界匹配** 是获得分数的首要门槛。
- 不同随机种子训练出的抽取边界极易发生 1-2 个字词的左右偏移。投票机制能显著**平滑边界噪音**，过滤低置信度候选。
- **回归值的融合**：五种子对 Valence & Arousal 回归均值取平均，消除了单一回归头的极端倾向。

负面结果与经验教训 / NEGATIVE RESULTS & DISCUSSION

# 学术诚实：并不是所有看似高大上的技术都管用

## CRF 序列解码失效

我们在提取头后尝试加入线性链条件随机场 (CRF)，认为其对 BIO 序列强约束有帮助。但开发集指标从 **0.6278 降低至 0.6249**。原因为 CRF 复杂的转移概率在不充足的小样本数据上极其容易产生严重的过拟合。

## 大模型/跨编码器候选融合受阻

通过将 DeepSeek 的生成候选四元组与编码器预测集做 Smart Fusion，指标不仅未提升反而产生下滑。原因是 LLM 抽取的泛化能力虽然强，但**带来了较多的实体-类别误判 (False Positives)**，大幅拉低了 cF1 精度。

## 对 Paraphrase 文本的过度过滤

COMET 质量过滤是一把双刃剑。适度筛选 (0.96) 帮助巨大，但提高到 **0.965** 时，日文 cF1 反而下跌（**0.356 -> 0.341**）。一味追求极高翻译质量导致了可用文本量骤降，发生了严重的欠拟合。

## 自动不确定性损失加权不稳定

尝试使用自动多任务不确定性损失加权（Uncertainty Weighting），期望平衡分类、回归、抽取的 Loss 比例。然而系统在各语言上表现极其动荡，远没有**固定人工调谐的权重 (2:1:1:1)** 来的鲁棒。

总结与展望 / CONCLUSION & FUTURE WORK

# LEADER-DimASQP 系统工作总结

## 工作总结与核心贡献 (Takeaways)

- **双层保障体系**：以 **Rethink反馈反馈机制** + **匈牙利匹配** 作为架构根基，提供高精度的提取与端到端回归融合路径。
- **验证驱动的数据配置**：揭示了多语言维度 ASQP 的本质——不该寻求“单药治百病”的完美模型。**特定分词、后处理裁剪 (如 MeCab) 和数据增强方案**对垂直语言才具有实质成效。
- **验证成果斐然**：以 **0.5008** 均值完美打底，在学术界与官方基线竞赛中呈现了绝对统治力。

## 学术展望与未来改进方向 (Future Directions)

- **类别感知联合解码**：目前提取与分类仍有轻微隔阂，未来可在解码器端注入 Entity-Attribute 先验限制，彻底消除实体-类别冲突。
- **V-A 概率分布回归**：利用分布预测（如 Beta 分布或 GMM）代替现在的标量点回归，解决倾向均值的收缩问题。
- **多语言表示微观对齐**：在共享多语空间（如 XLM-R）上做跨语语义投影，进一步降低 Tatar 等小语种极度少样本的冷启动损耗。

**汇报结束，欢迎各位老师和同学批评指正！**

**联系邮箱: g24tka12@yamanashi.ac.jp | rjzhou@hdu.edu.cn**

参考文献 / REFERENCES

# 学术规范：主要的参考文献清单


- [1] **Lee et al. (2026)**. DimABSA: Building multilingual and multidomain datasets for dimensional aspect-based sentiment analysis. *arXiv:2601.23022*.

- [2] **Yu et al. (2026)**. SemEval-2026 Task 3: Dimensional aspect-based sentiment analysis (DimABSA). *arXiv:2604.07066*.

- [3] **Carion et al. (2020)**. End-to-end object detection with transformers. In *Proceedings of ECCV*.

- [4] **He et al. (2023)**. DeBERTaV3: Improving DeBERTa using ELECTRA-style pre-training with gradient-disentangled embedding sharing. In *Proceedings of ICLR*.

- [5] **Kuhn (1955)**. The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2), 83-97.